

UJIAN AKHIR SEMESTER

Klasifikasi Kaca Menggunakan *Learning Vector Quantization* (Studi Identifikasi dan Klasifikasi Jenis Kaca Berdasarkan Indeks Bias dan Komposisi Unsur)

Disusun untuk memenuhi Ujian Akhir Semester Jaringan Syaraf Tiruan

Dosen Pengampu: Dr. Sri Andayani, S.Si., M.Kom & Fatma Agus Setyaningsih S.Kom.,
M.Cs.



Disusun Oleh:

Muhammad Nashiruddin Al Bani (21309144019)

Statistika G 2021

PROGRAM STUDI STATISTIKA

DEPARTEMEN PENDIDIKAN MATEMATIKA

FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM

UNIVERSITAS NEGERI YOGYAKARTA

2024

DAFTAR ISI

DAFTAR ISI.....	2
A. Pendahuluan.....	3
• Klasifikasi.....	3
• Jaringan Syaraf Tiruan.....	3
• <i>Learning Vector Quantization (LVQ)</i>	3
• Algoritma <i>Learning Vector Quantization (LVQ)</i>	3
B. Deskripsi Data.....	4
C. Struktur dan Arsitektur.....	10
D. Langkah - Langkah.....	10
E. Output.....	11
F. Akurasi Setiap Fold dan Rata – Rata Akurasi.....	13
G. Listing Program.....	20
H. Referensi.....	23

A. Pendahuluan

- **Klasifikasi**

Klasifikasi adalah suatu proses menemukan model atau fungsi yang mendeskripsikan atau membedakan kategori kelas data yang tujuan untuk memperkirakan kelas dari suatu objek yang labelnya belum diketahui. Tahapan klasifikasi dalam data mining meliputi: (1) Pengembangan model, (2) Penerapan model, (3) Evaluasi. Proses klasifikasi didasarkan pada empat bagian, yaitu: (1) Kelas; variabel dependen berupa kategori yang merepresentasikan “label” yang terdapat pada objek. Contoh: jenis penyakit, (2) Presictor; variabel independent (variable bebas) yang diwakili oleh karakteristik (atribut) data. Contoh: batuk atau tidak, pusing atau tidak, (3) Training dataset; satu set data yang berisi nilai-nilai dari dua komponen diatas, digunakan untuk menentukan kelas yang sesuai berdasarkan predictor, (4) Testing dataset; digunakan untuk mengklasifikasi data baru oleh model yang telah dibuat dan mengevaluasi akurasi klasifikasi

- **Jaringan Syaraf Tiruan**

Jaringan syaraf tiruan (artificial neural network), atau disingkat JST merupakan salah satu sistem pemrosesan informasi yang didesain dengan menirukan cara kerja otak manusia dalam menyelesaikan suatu masalah dengan melakukan proses belajar melalui perubahan bobot sinapsisnya. Jaringan Syaraf Tiruan (JST) mampu mengenali kegiatan dengan berbasis pada data masa lalu. Data masa lalu akan dipelajari oleh JST sehingga mempunyai kemampuan untuk memberi Keputusan terhadap data yang belum pernah dipelajari (Larandipa et al., 2013)

- ***Learning Vector Quantization (LVQ)***

Learning Vector Quantization (LVQ) adalah metode klasifikasi pada pola untuk setiap unit yang ada, dan output-nya akan mempresentasikan kategori tertentu atau kelas yang telah ditentukan sebelumnya. Kelaskelas yang diperoleh akan bergantung pada jarak antar vektor input. LVQ juga merupakan metode pelatihan yang dilakukan dalam supervised learning (pembelajaran yang terawasi) dan termasuk dalam kategori single layer, artinya hanya memiliki layer input dan layer output yang saling terhubung dengan adanya suatu bobot (weight) (Fausett, 1994)

- ***Algoritma Learning Vector Quantization (LVQ)***

Langkah-langkah algoritma pelatihan LVQ (Fausett, 1994):

1. Tahap awal adalah menginisialisasi nilai learning rate (α), pengurangan learning rate, maksimal epoch yang digunakan dan minimal learning rate yang akan digunakan serta menentukan bobot awal setiap kelas atau target.
2. Masukkan data input serta kelas atau kategori target.
3. Kerjakan apabila ($epoch \leq \max epoch$ dan $\alpha \geq \min \alpha$):
 - a. Epoch = epoch + 1
 - b. Melakukan perhitungan jarak minimum dengan menggunakan *Euclidean distance*

$$D_i = \sqrt{\sum_{j=1}^n (x_j - w_{ij})^2}$$
 - c. Melakukan update bobot untuk memperbaiki nilai bobot dengan kondisi:
Jika $T = C_j$ maka:
 $w_j(\text{baru}) = w_j(\text{lama}) + \alpha (x_i - w_j(\text{lama}))$
Jika $T \neq C_j$ maka:
 $w_j(\text{baru}) = w_j(\text{lama}) - \alpha (x_i - w_j(\text{lama}))$
 - d. Melakukan pengurangan pada nilai α dengan cara:
4. Proses akan berhenti jika telah mencapai maksimum epoch atau nilai learning rate (α) telah minimum.
5. Setelah proses pelatihan selesai, maka akan diperoleh bobot-bobot akhir (w).

B. Deskripsi Data

Penelitian ini, data yang digunakan adalah data sekunder. ini berisi 214 sampel kaca yang diklasifikasikan berdasarkan jenis dan proses pembuatannya, berguna untuk keperluan investigasi kriminal. Setiap sampel memiliki 10 atribut numerik yang menggambarkan sifat fisik dan kimia, yaitu: nomor ID, indeks bias (RI), kandungan Natrium (Na), Magnesium (Mg), Aluminium (Al), Silikon (Si), Kalium (K), Kalsium (Ca), Barium (Ba), dan Besi (Fe). Jenis kaca yang menjadi atribut kelas atau variabel target mencakup tujuh kategori: kaca jendela bangunan yang diproses float, kaca jendela bangunan yang tidak diproses float, kaca jendela kendaraan yang diproses float, kaca jendela kendaraan yang tidak diproses float (tidak ada dalam database ini), wadah, peralatan makan, dan lampu depan. Data ini tidak memiliki nilai atribut yang hilang. Statistik ringkasan menunjukkan rentang, rata-rata, standar deviasi, dan korelasi tiap atribut dengan kelas. Distribusi kelas di dalam database adalah 163

sampel kaca jendela (87 diproses float, 76 tidak diproses float) dan 51 sampel kaca non-jendela (13 wadah, 9 peralatan makan, 29 lampu depan).

RI	Na	Mg	Al	Si	K	Ca	Ba	Fe	Type
1.52101	13.64	4.49	1.1	71.78	0.06	8.75	0	0	1
1.51761	13.89	3.6	1.36	72.73	0.48	7.83	0	0	1
1.51618	13.53	3.55	1.54	72.99	0.39	7.78	0	0	1
1.51766	13.21	3.69	1.29	72.61	0.57	8.22	0	0	1
1.51742	13.27	3.62	1.24	73.08	0.55	8.07	0	0	1
1.51596	12.79	3.61	1.62	72.97	0.64	8.07	0	0.26	1
1.51743	13.3	3.6	1.14	73.09	0.58	8.17	0	0	1
1.51756	13.15	3.61	1.05	73.24	0.57	8.24	0	0	1
1.51918	14.04	3.58	1.37	72.08	0.56	8.3	0	0	1
1.51755	13	3.6	1.36	72.99	0.57	8.4	0	0.11	1
1.51571	12.72	3.46	1.56	73.2	0.67	8.09	0	0.24	1
1.51763	12.8	3.66	1.27	73.01	0.6	8.56	0	0	1
1.51589	12.88	3.43	1.4	73.28	0.69	8.05	0	0.24	1
1.51748	12.86	3.56	1.27	73.21	0.54	8.38	0	0.17	1
1.51763	12.61	3.59	1.31	73.29	0.58	8.5	0	0	1
1.51761	12.81	3.54	1.23	73.24	0.58	8.39	0	0	1
1.51784	12.68	3.67	1.16	73.11	0.61	8.7	0	0	1
1.52196	14.36	3.85	0.89	71.36	0.15	9.15	0	0	1
1.51911	13.9	3.73	1.18	72.12	0.06	8.89	0	0	1
1.51735	13.02	3.54	1.69	72.73	0.54	8.44	0	0.07	1
1.5175	12.82	3.55	1.49	72.75	0.54	8.52	0	0.19	1
1.51966	14.77	3.75	0.29	72.02	0.03	9	0	0	1
1.51736	12.78	3.62	1.29	72.79	0.59	8.7	0	0	1
1.51751	12.81	3.57	1.35	73.02	0.62	8.59	0	0	1
1.5172	13.38	3.5	1.15	72.85	0.5	8.43	0	0	1
1.51764	12.98	3.54	1.21	73	0.65	8.53	0	0	1
1.51793	13.21	3.48	1.41	72.64	0.59	8.43	0	0	1
1.51721	12.87	3.48	1.33	73.04	0.56	8.43	0	0	1
1.51768	12.56	3.52	1.43	73.15	0.57	8.54	0	0	1
1.51784	13.08	3.49	1.28	72.86	0.6	8.49	0	0	1
1.51768	12.65	3.56	1.3	73.08	0.61	8.69	0	0.14	1
1.51747	12.84	3.5	1.14	73.27	0.56	8.55	0	0	1
1.51775	12.85	3.48	1.23	72.97	0.61	8.56	0.09	0.22	1
1.51753	12.57	3.47	1.38	73.39	0.6	8.55	0	0.06	1
1.51783	12.69	3.54	1.34	72.95	0.57	8.75	0	0	1
1.51567	13.29	3.45	1.21	72.74	0.56	8.57	0	0	1
1.51909	13.89	3.53	1.32	71.81	0.51	8.78	0.11	0	1
1.51797	12.74	3.48	1.35	72.96	0.64	8.68	0	0	1

1.52213	14.21	3.82	0.47	71.77	0.11	9.57	0	0	1
1.52213	14.21	3.82	0.47	71.77	0.11	9.57	0	0	1
1.51793	12.79	3.5	1.12	73.03	0.64	8.77	0	0	1
1.51755	12.71	3.42	1.2	73.2	0.59	8.64	0	0	1
1.51779	13.21	3.39	1.33	72.76	0.59	8.59	0	0	1
1.5221	13.73	3.84	0.72	71.76	0.17	9.74	0	0	1
1.51786	12.73	3.43	1.19	72.95	0.62	8.76	0	0.3	1
1.519	13.49	3.48	1.35	71.95	0.55	9	0	0	1
1.51869	13.19	3.37	1.18	72.72	0.57	8.83	0	0.16	1
1.52667	13.99	3.7	0.71	71.57	0.02	9.82	0	0.1	1
1.52223	13.21	3.77	0.79	71.99	0.13	10.02	0	0	1
1.51898	13.58	3.35	1.23	72.08	0.59	8.91	0	0	1
1.5232	13.72	3.72	0.51	71.75	0.09	10.06	0	0.16	1
1.51926	13.2	3.33	1.28	72.36	0.6	9.14	0	0.11	1
1.51808	13.43	2.87	1.19	72.84	0.55	9.03	0	0	1
1.51837	13.14	2.84	1.28	72.85	0.55	9.07	0	0	1
1.51778	13.21	2.81	1.29	72.98	0.51	9.02	0	0.09	1
1.51769	12.45	2.71	1.29	73.7	0.56	9.06	0	0.24	1
1.51215	12.99	3.47	1.12	72.98	0.62	8.35	0	0.31	1
1.51824	12.87	3.48	1.29	72.95	0.6	8.43	0	0	1
1.51754	13.48	3.74	1.17	72.99	0.59	8.03	0	0	1
1.51754	13.39	3.66	1.19	72.79	0.57	8.27	0	0.11	1
1.51905	13.6	3.62	1.11	72.64	0.14	8.76	0	0	1
1.51977	13.81	3.58	1.32	71.72	0.12	8.67	0.69	0	1
1.52172	13.51	3.86	0.88	71.79	0.23	9.54	0	0.11	1
1.52227	14.17	3.81	0.78	71.35	0	9.69	0	0	1
1.52172	13.48	3.74	0.9	72.01	0.18	9.61	0	0.07	1
1.52099	13.69	3.59	1.12	71.96	0.09	9.4	0	0	1
1.52152	13.05	3.65	0.87	72.22	0.19	9.85	0	0.17	1
1.52152	13.05	3.65	0.87	72.32	0.19	9.85	0	0.17	1
1.52152	13.12	3.58	0.9	72.2	0.23	9.82	0	0.16	1
1.523	13.31	3.58	0.82	71.99	0.12	10.17	0	0.03	1
1.51574	14.86	3.67	1.74	71.87	0.16	7.36	0	0.12	2
1.51848	13.64	3.87	1.27	71.96	0.54	8.32	0	0.32	2
1.51593	13.09	3.59	1.52	73.1	0.67	7.83	0	0	2
1.51631	13.34	3.57	1.57	72.87	0.61	7.89	0	0	2
1.51596	13.02	3.56	1.54	73.11	0.72	7.9	0	0	2
1.5159	13.02	3.58	1.51	73.12	0.69	7.96	0	0	2
1.51645	13.44	3.61	1.54	72.39	0.66	8.03	0	0	2
1.51627	13	3.58	1.54	72.83	0.61	8.04	0	0	2
1.51613	13.92	3.52	1.25	72.88	0.37	7.94	0	0.14	2
1.5159	12.82	3.52	1.9	72.86	0.69	7.97	0	0	2

1.51592	12.86	3.52	2.12	72.66	0.69	7.97	0	0	2
1.51593	13.25	3.45	1.43	73.17	0.61	7.86	0	0	2
1.51646	13.41	3.55	1.25	72.81	0.68	8.1	0	0	2
1.51594	13.09	3.52	1.55	72.87	0.68	8.05	0	0.09	2
1.51409	14.25	3.09	2.08	72.28	1.1	7.08	0	0	2
1.51625	13.36	3.58	1.49	72.72	0.45	8.21	0	0	2
1.51569	13.24	3.49	1.47	73.25	0.38	8.03	0	0	2
1.51645	13.4	3.49	1.52	72.65	0.67	8.08	0	0.1	2
1.51618	13.01	3.5	1.48	72.89	0.6	8.12	0	0	2
1.5164	12.55	3.48	1.87	73.23	0.63	8.08	0	0.09	2
1.51841	12.93	3.74	1.11	72.28	0.64	8.96	0	0.22	2
1.51605	12.9	3.44	1.45	73.06	0.44	8.27	0	0	2
1.51588	13.12	3.41	1.58	73.26	0.07	8.39	0	0.19	2
1.5159	13.24	3.34	1.47	73.1	0.39	8.22	0	0	2
1.51629	12.71	3.33	1.49	73.28	0.67	8.24	0	0	2
1.5186	13.36	3.43	1.43	72.26	0.51	8.6	0	0	2
1.51841	13.02	3.62	1.06	72.34	0.64	9.13	0	0.15	2
1.51743	12.2	3.25	1.16	73.55	0.62	8.9	0	0.24	2
1.51689	12.67	2.88	1.71	73.21	0.73	8.54	0	0	2
1.51811	12.96	2.96	1.43	72.92	0.6	8.79	0.14	0	2
1.51655	12.75	2.85	1.44	73.27	0.57	8.79	0.11	0.22	2
1.5173	12.35	2.72	1.63	72.87	0.7	9.23	0	0	2
1.5182	12.62	2.76	0.83	73.81	0.35	9.42	0	0.2	2
1.52725	13.8	3.15	0.66	70.57	0.08	11.64	0	0	2
1.5241	13.83	2.9	1.17	71.15	0.08	10.79	0	0	2
1.52475	11.45	0	1.88	72.19	0.81	13.24	0	0.34	2
1.53125	10.73	0	2.1	69.81	0.58	13.3	3.15	0.28	2
1.53393	12.3	0	1	70.16	0.12	16.19	0	0.24	2
1.52222	14.43	0	1	72.67	0.1	11.52	0	0.08	2
1.51818	13.72	0	0.56	74.45	0	10.99	0	0	2
1.52664	11.23	0	0.77	73.21	0	14.68	0	0	2
1.52739	11.02	0	0.75	73.08	0	14.96	0	0	2
1.52777	12.64	0	0.67	72.02	0.06	14.4	0	0	2
1.51892	13.46	3.83	1.26	72.55	0.57	8.21	0	0.14	2
1.51847	13.1	3.97	1.19	72.44	0.6	8.43	0	0	2
1.51846	13.41	3.89	1.33	72.38	0.51	8.28	0	0	2
1.51829	13.24	3.9	1.41	72.33	0.55	8.31	0	0.1	2
1.51708	13.72	3.68	1.81	72.06	0.64	7.88	0	0	2
1.51673	13.3	3.64	1.53	72.53	0.65	8.03	0	0.29	2
1.51652	13.56	3.57	1.47	72.45	0.64	7.96	0	0	2
1.51844	13.25	3.76	1.32	72.4	0.58	8.42	0	0	2
1.51663	12.93	3.54	1.62	72.96	0.64	8.03	0	0.21	2

1.51687	13.23	3.54	1.48	72.84	0.56	8.1	0	0	2
1.51707	13.48	3.48	1.71	72.52	0.62	7.99	0	0	2
1.52177	13.2	3.68	1.15	72.75	0.54	8.52	0	0	2
1.51872	12.93	3.66	1.56	72.51	0.58	8.55	0	0.12	2
1.51667	12.94	3.61	1.26	72.75	0.56	8.6	0	0	2
1.52081	13.78	2.28	1.43	71.99	0.49	9.85	0	0.17	2
1.52068	13.55	2.09	1.67	72.18	0.53	9.57	0.27	0.17	2
1.5202	13.98	1.35	1.63	71.76	0.39	10.56	0	0.18	2
1.52177	13.75	1.01	1.36	72.19	0.33	11.14	0	0	2
1.52614	13.7	0	1.36	71.24	0.19	13.44	0	0.1	2
1.51813	13.43	3.98	1.18	72.49	0.58	8.15	0	0	2
1.518	13.71	3.93	1.54	71.81	0.54	8.21	0	0.15	2
1.51811	13.33	3.85	1.25	72.78	0.52	8.12	0	0	2
1.51789	13.19	3.9	1.3	72.33	0.55	8.44	0	0.28	2
1.51806	13	3.8	1.08	73.07	0.56	8.38	0	0.12	2
1.51711	12.89	3.62	1.57	72.96	0.61	8.11	0	0	2
1.51674	12.79	3.52	1.54	73.36	0.66	7.9	0	0	2
1.51674	12.87	3.56	1.64	73.14	0.65	7.99	0	0	2
1.5169	13.33	3.54	1.61	72.54	0.68	8.11	0	0	2
1.51851	13.2	3.63	1.07	72.83	0.57	8.41	0.09	0.17	2
1.51662	12.85	3.51	1.44	73.01	0.68	8.23	0.06	0.25	2
1.51709	13	3.47	1.79	72.72	0.66	8.18	0	0	2
1.5166	12.99	3.18	1.23	72.97	0.58	8.81	0	0.24	2
1.51839	12.85	3.67	1.24	72.57	0.62	8.68	0	0.35	2
1.51769	13.65	3.66	1.11	72.77	0.11	8.6	0	0	3
1.5161	13.33	3.53	1.34	72.67	0.56	8.33	0	0	3
1.5167	13.24	3.57	1.38	72.7	0.56	8.44	0	0.1	3
1.51643	12.16	3.52	1.35	72.89	0.57	8.53	0	0	3
1.51665	13.14	3.45	1.76	72.48	0.6	8.38	0	0.17	3
1.52127	14.32	3.9	0.83	71.5	0	9.49	0	0	3
1.51779	13.64	3.65	0.65	73	0.06	8.93	0	0	3
1.5161	13.42	3.4	1.22	72.69	0.59	8.32	0	0	3
1.51694	12.86	3.58	1.31	72.61	0.61	8.79	0	0	3
1.51646	13.04	3.4	1.26	73.01	0.52	8.58	0	0	3
1.51655	13.41	3.39	1.28	72.64	0.52	8.65	0	0	3
1.52121	14.03	3.76	0.58	71.79	0.11	9.65	0	0	3
1.51776	13.53	3.41	1.52	72.04	0.58	8.79	0	0	3
1.51796	13.5	3.36	1.63	71.94	0.57	8.81	0	0.09	3
1.51832	13.33	3.34	1.54	72.14	0.56	8.99	0	0	3
1.51934	13.64	3.54	0.75	72.65	0.16	8.89	0.15	0.24	3
1.52211	14.19	3.78	0.91	71.36	0.23	9.14	0	0.37	3
1.51514	14.01	2.68	3.5	69.89	1.68	5.87	2.2	0	5


1.51915	12.73	1.85	1.86	72.69	0.6	10.09	0	0	5
1.52171	11.56	1.88	1.56	72.86	0.47	11.41	0	0	5
1.52151	11.03	1.71	1.56	73.44	0.58	11.62	0	0	5
1.51969	12.64	0	1.65	73.75	0.38	11.53	0	0	5
1.51666	12.86	0	1.83	73.88	0.97	10.17	0	0	5
1.51994	13.27	0	1.76	73.03	0.47	11.32	0	0	5
1.52369	13.44	0	1.58	72.22	0.32	12.24	0	0	5
1.51316	13.02	0	3.04	70.48	6.21	6.96	0	0	5
1.51321	13	0	3.02	70.7	6.21	6.93	0	0	5
1.52043	13.38	0	1.4	72.25	0.33	12.5	0	0	5
1.52058	12.85	1.61	2.17	72.18	0.76	9.7	0.24	0.51	5
1.52119	12.97	0.33	1.51	73.39	0.13	11.27	0	0.28	5
1.51905	14	2.39	1.56	72.37	0	9.57	0	0	6
1.51937	13.79	2.41	1.19	72.76	0	9.77	0	0	6
1.51829	14.46	2.24	1.62	72.38	0	9.26	0	0	6
1.51852	14.09	2.19	1.66	72.67	0	9.32	0	0	6
1.51299	14.4	1.74	1.54	74.55	0	7.59	0	0	6
1.51888	14.99	0.78	1.74	72.5	0	9.95	0	0	6
1.51916	14.15	0	2.09	72.74	0	10.88	0	0	6
1.51969	14.56	0	0.56	73.48	0	11.22	0	0	6
1.51115	17.38	0	0.34	75.41	0	6.65	0	0	6
1.51131	13.69	3.2	1.81	72.81	1.76	5.43	1.19	0	7
1.51838	14.32	3.26	2.22	71.25	1.46	5.79	1.63	0	7
1.52315	13.44	3.34	1.23	72.38	0.6	8.83	0	0	7
1.52247	14.86	2.2	2.06	70.26	0.76	9.76	0	0	7
1.52365	15.79	1.83	1.31	70.43	0.31	8.61	1.68	0	7
1.51613	13.88	1.78	1.79	73.1	0	8.67	0.76	0	7
1.51602	14.85	0	2.38	73.28	0	8.76	0.64	0.09	7
1.51623	14.2	0	2.79	73.46	0.04	9.04	0.4	0.09	7
1.51719	14.75	0	2	73.02	0	8.53	1.59	0.08	7
1.51683	14.56	0	1.98	73.29	0	8.52	1.57	0.07	7
1.51545	14.14	0	2.68	73.39	0.08	9.07	0.61	0.05	7
1.51556	13.87	0	2.54	73.23	0.14	9.41	0.81	0.01	7
1.51727	14.7	0	2.34	73.28	0	8.95	0.66	0	7
1.51531	14.38	0	2.66	73.1	0.04	9.08	0.64	0	7
1.51609	15.01	0	2.51	73.05	0.05	8.83	0.53	0	7
1.51508	15.15	0	2.25	73.5	0	8.34	0.63	0	7
1.51653	11.95	0	1.19	75.18	2.7	8.93	0	0	7
1.51514	14.85	0	2.42	73.72	0	8.39	0.56	0	7
1.51658	14.8	0	1.99	73.11	0	8.28	1.71	0	7
1.51617	14.95	0	2.27	73.3	0	8.71	0.67	0	7
1.51732	14.95	0	1.8	72.99	0	8.61	1.55	0	7

1.51645	14.94	0	1.87	73.11	0	8.67	1.38	0	7
1.51831	14.39	0	1.82	72.86	1.41	6.47	2.88	0	7
1.5164	14.37	0	2.74	72.85	0	9.45	0.54	0	7
1.51623	14.14	0	2.88	72.61	0.08	9.18	1.06	0	7
1.51685	14.92	0	1.99	73.06	0	8.4	1.59	0	7
1.52065	14.36	0	2.02	73.42	0	8.44	1.64	0	7
1.51651	14.38	0	1.94	73.61	0	8.48	1.57	0	7
1.51711	14.23	0	2.08	73.36	0	8.62	1.67	0	7

C. Struktur dan Arsitektur


Pada penelitian ini yang dijadikan objek merupakan klasifikasi jenis kaca berdasarkan karakteristik fisik dan kimia yang diukur, seperti indeks bias dan kandungan unsur-unsur kimia (Natrium, Magnesium, Aluminium, Silikon, Kalium, Kalsium, Barium, dan Besi). Penelitian ini bertujuan untuk mengidentifikasi jenis kaca yang ditemukan di lokasi kejadian kriminal, baik itu kaca jendela bangunan, kaca jendela kendaraan, wadah, peralatan makan, atau lampu depan.

D. Langkah - Langkah



E. Output

Untuk melakukan klasifikasi menggunakan metode Learning Vector Quantization (LVQ), langkah pertama adalah mengimpor data yang telah diubah menjadi format .csv ke dalam bahasa pemrograman Python. Setelah data berhasil dimuat ke dalam Python, langkah berikutnya adalah memeriksa ukuran dataset untuk memastikan kesesuaiannya dengan dataset yang telah disiapkan sebelumnya. Berikut ini adalah lima baris pertama dari dataset yang digunakan:



	RI	Na	Mg	Al	Si	K	Ca	Ba	Fe	Type
0	1.52101	13.64	4.49	1.10	71.78	0.06	8.75	0.0	0.0	1
1	1.51761	13.89	3.60	1.36	72.73	0.48	7.83	0.0	0.0	1
2	1.51618	13.53	3.55	1.54	72.99	0.39	7.78	0.0	0.0	1
3	1.51766	13.21	3.69	1.29	72.61	0.57	8.22	0.0	0.0	1
4	1.51742	13.27	3.62	1.24	73.08	0.55	8.07	0.0	0.0	1

Next steps: ☒ View recommended plots

Dataset ini telah melalui proses pembersihan, yang mencakup penghapusan data yang tidak lengkap (missing value), transformasi data, dan konversi data agar siap digunakan dalam tahap klasifikasi. Setelah itu, numpy digunakan untuk mendapatkan statistik deskriptif dari dataset yang ada. Berikut adalah statistik deskriptif yang diperoleh menggunakan Python.



	count	mean	std	min	25%	50%	75%	max
RI	214.0	1.518365	0.003037	1.51115	1.516522	1.51768	1.519157	1.53393
Na	214.0	13.407850	0.816604	10.73000	12.907500	13.30000	13.825000	17.38000
Mg	214.0	2.684533	1.442408	0.00000	2.115000	3.48000	3.600000	4.49000
Al	214.0	1.444907	0.499270	0.29000	1.190000	1.36000	1.630000	3.50000
Si	214.0	72.650935	0.774546	69.81000	72.280000	72.79000	73.087500	75.41000
K	214.0	0.497056	0.652192	0.00000	0.122500	0.55500	0.610000	6.21000
Ca	214.0	8.956963	1.423153	5.43000	8.240000	8.60000	9.172500	16.19000
Ba	214.0	0.175047	0.497219	0.00000	0.000000	0.00000	0.000000	3.15000
Fe	214.0	0.057009	0.097439	0.00000	0.000000	0.00000	0.100000	0.51000

Parameter Model

```
Parameter:  
Learning Rate: 0.1  
Epochs: 25  
Number of Subsets: 50  
Number of Folds: 5
```

1. Learning Rate (Laju Pembelajaran): 0.1

- **Interpretasi:** Learning rate menentukan seberapa besar perubahan yang dilakukan pada vektor subset representatif selama proses pembelajaran pada setiap epoch. Dengan nilai 0.1, setiap update pada subset representatif dilakukan dengan perubahan yang relatif besar pada awal pelatihan.
- **Pengaruh:** Learning rate yang lebih tinggi mempercepat proses pembelajaran, tetapi juga bisa menyebabkan osilasi jika terlalu tinggi. Sebaliknya, learning rate yang terlalu rendah dapat memperlambat pembelajaran. Dalam proses ini, learning rate menurun secara bertahap, memungkinkan penyesuaian yang lebih halus di akhir pelatihan.

2. Epochs (Jumlah Epoch): 25

- **Interpretasi:** Epoch adalah satu kali iterasi penuh melalui seluruh dataset. Dengan 25 epochs, model dilatih melalui dataset sebanyak 25 kali.
- **Pengaruh:** Lebih banyak epoch biasanya memungkinkan model untuk belajar lebih baik, tetapi terlalu banyak epoch bisa menyebabkan overfitting, di mana model belajar terlalu baik pada data latih namun kurang mampu menggeneralisasi data baru.

3. Number of Subsets (Jumlah Subset): 50

- **Interpretasi:** Jumlah subset adalah jumlah vektor representatif yang digunakan untuk mengklasifikasikan data dalam dataset. Setiap subset mewakili cluster atau kelas dalam data.
- **Pengaruh:** Lebih banyak subset memungkinkan representasi yang lebih detail dari data, tetapi juga meningkatkan kompleksitas dan waktu komputasi.


Jumlah subset yang terlalu sedikit mungkin tidak cukup untuk menangkap variasi dalam data.

4. Number of Folds (Jumlah Fold): 5

- **Interpretasi:** Jumlah fold dalam K-Fold Cross-Validation adalah jumlah bagian yang data dibagi untuk proses validasi silang. Dalam kasus ini, data dibagi menjadi 5 fold.
- **Pengaruh:** K-Fold Cross-Validation membantu dalam mengevaluasi model dengan lebih andal, karena setiap bagian data digunakan sebagai data uji sekali dan data latih beberapa kali. Ini membantu mengurangi bias dalam evaluasi model dan memberikan gambaran yang lebih akurat tentang performa model.

F. Akurasi Setiap Fold dan Rata – Rata Akurasi


```
Fold 1
Epoch 1/25, Learning Rate: 0.100, Accuracy: 48.81%
Epoch 2/25, Learning Rate: 0.096, Accuracy: 67.26%
Epoch 3/25, Learning Rate: 0.092, Accuracy: 72.62%
Epoch 4/25, Learning Rate: 0.088, Accuracy: 69.64%
Epoch 5/25, Learning Rate: 0.084, Accuracy: 71.43%
Epoch 6/25, Learning Rate: 0.080, Accuracy: 73.21%
Epoch 7/25, Learning Rate: 0.076, Accuracy: 73.81%
Epoch 8/25, Learning Rate: 0.072, Accuracy: 73.21%
Epoch 9/25, Learning Rate: 0.068, Accuracy: 74.40%
Epoch 10/25, Learning Rate: 0.064, Accuracy: 75.60%
Epoch 11/25, Learning Rate: 0.060, Accuracy: 75.60%
Epoch 12/25, Learning Rate: 0.056, Accuracy: 75.00%
Epoch 13/25, Learning Rate: 0.052, Accuracy: 75.60%
Epoch 14/25, Learning Rate: 0.048, Accuracy: 76.19%
Epoch 15/25, Learning Rate: 0.044, Accuracy: 76.19%
Epoch 16/25, Learning Rate: 0.040, Accuracy: 76.79%
Epoch 17/25, Learning Rate: 0.036, Accuracy: 76.79%
Epoch 18/25, Learning Rate: 0.032, Accuracy: 77.38%
Epoch 19/25, Learning Rate: 0.028, Accuracy: 77.38%
Epoch 20/25, Learning Rate: 0.024, Accuracy: 77.38%
Epoch 21/25, Learning Rate: 0.020, Accuracy: 77.38%
Epoch 22/25, Learning Rate: 0.016, Accuracy: 77.38%
Epoch 23/25, Learning Rate: 0.012, Accuracy: 77.38%
Epoch 24/25, Learning Rate: 0.008, Accuracy: 77.38%
Epoch 25/25, Learning Rate: 0.004, Accuracy: 77.38%
Fold 1 Accuracy: 59.52%
```



Fold 2

Epoch 1/25, Learning Rate: 0.100, Accuracy: 31.55%
Epoch 2/25, Learning Rate: 0.096, Accuracy: 59.52%
Epoch 3/25, Learning Rate: 0.092, Accuracy: 66.07%
Epoch 4/25, Learning Rate: 0.088, Accuracy: 69.05%
Epoch 5/25, Learning Rate: 0.084, Accuracy: 69.64%
Epoch 6/25, Learning Rate: 0.080, Accuracy: 70.83%
Epoch 7/25, Learning Rate: 0.076, Accuracy: 74.40%
Epoch 8/25, Learning Rate: 0.072, Accuracy: 76.19%
Epoch 9/25, Learning Rate: 0.068, Accuracy: 76.19%
Epoch 10/25, Learning Rate: 0.064, Accuracy: 76.79%
Epoch 11/25, Learning Rate: 0.060, Accuracy: 79.17%
Epoch 12/25, Learning Rate: 0.056, Accuracy: 77.98%
Epoch 13/25, Learning Rate: 0.052, Accuracy: 76.19%
Epoch 14/25, Learning Rate: 0.048, Accuracy: 76.19%
Epoch 15/25, Learning Rate: 0.044, Accuracy: 77.38%
Epoch 16/25, Learning Rate: 0.040, Accuracy: 75.60%
Epoch 17/25, Learning Rate: 0.036, Accuracy: 75.60%
Epoch 18/25, Learning Rate: 0.032, Accuracy: 75.60%
Epoch 19/25, Learning Rate: 0.028, Accuracy: 74.40%
Epoch 20/25, Learning Rate: 0.024, Accuracy: 75.60%
Epoch 21/25, Learning Rate: 0.020, Accuracy: 76.19%
Epoch 22/25, Learning Rate: 0.016, Accuracy: 76.19%
Epoch 23/25, Learning Rate: 0.012, Accuracy: 75.60%
Epoch 24/25, Learning Rate: 0.008, Accuracy: 75.60%
Epoch 25/25, Learning Rate: 0.004, Accuracy: 75.60%


Fold 2 Accuracy: 78.57%



Fold 3

Epoch 1/25, Learning Rate: 0.100, Accuracy: 43.45%
Epoch 2/25, Learning Rate: 0.096, Accuracy: 60.12%
Epoch 3/25, Learning Rate: 0.092, Accuracy: 66.07%
Epoch 4/25, Learning Rate: 0.088, Accuracy: 67.26%
Epoch 5/25, Learning Rate: 0.084, Accuracy: 68.45%
Epoch 6/25, Learning Rate: 0.080, Accuracy: 70.24%
Epoch 7/25, Learning Rate: 0.076, Accuracy: 68.45%
Epoch 8/25, Learning Rate: 0.072, Accuracy: 69.05%
Epoch 9/25, Learning Rate: 0.068, Accuracy: 69.64%
Epoch 10/25, Learning Rate: 0.064, Accuracy: 68.45%
Epoch 11/25, Learning Rate: 0.060, Accuracy: 69.05%
Epoch 12/25, Learning Rate: 0.056, Accuracy: 69.64%
Epoch 13/25, Learning Rate: 0.052, Accuracy: 70.24%
Epoch 14/25, Learning Rate: 0.048, Accuracy: 70.83%
Epoch 15/25, Learning Rate: 0.044, Accuracy: 72.02%
Epoch 16/25, Learning Rate: 0.040, Accuracy: 70.83%
Epoch 17/25, Learning Rate: 0.036, Accuracy: 70.83%
Epoch 18/25, Learning Rate: 0.032, Accuracy: 70.24%
Epoch 19/25, Learning Rate: 0.028, Accuracy: 70.83%
Epoch 20/25, Learning Rate: 0.024, Accuracy: 70.24%
Epoch 21/25, Learning Rate: 0.020, Accuracy: 71.43%
Epoch 22/25, Learning Rate: 0.016, Accuracy: 70.83%
Epoch 23/25, Learning Rate: 0.012, Accuracy: 71.43%
Epoch 24/25, Learning Rate: 0.008, Accuracy: 71.43%
Epoch 25/25, Learning Rate: 0.004, Accuracy: 71.43%


Fold 3 Accuracy: 76.19%



Fold 4

Epoch 1/25, Learning Rate: 0.100, Accuracy: 37.50%
Epoch 2/25, Learning Rate: 0.096, Accuracy: 60.71%
Epoch 3/25, Learning Rate: 0.092, Accuracy: 64.88%
Epoch 4/25, Learning Rate: 0.088, Accuracy: 63.69%
Epoch 5/25, Learning Rate: 0.084, Accuracy: 66.07%
Epoch 6/25, Learning Rate: 0.080, Accuracy: 67.26%
Epoch 7/25, Learning Rate: 0.076, Accuracy: 67.26%
Epoch 8/25, Learning Rate: 0.072, Accuracy: 68.45%
Epoch 9/25, Learning Rate: 0.068, Accuracy: 67.26%
Epoch 10/25, Learning Rate: 0.064, Accuracy: 67.26%
Epoch 11/25, Learning Rate: 0.060, Accuracy: 68.45%
Epoch 12/25, Learning Rate: 0.056, Accuracy: 69.05%
Epoch 13/25, Learning Rate: 0.052, Accuracy: 70.83%
Epoch 14/25, Learning Rate: 0.048, Accuracy: 72.62%
Epoch 15/25, Learning Rate: 0.044, Accuracy: 72.62%
Epoch 16/25, Learning Rate: 0.040, Accuracy: 73.21%
Epoch 17/25, Learning Rate: 0.036, Accuracy: 72.62%
Epoch 18/25, Learning Rate: 0.032, Accuracy: 73.21%
Epoch 19/25, Learning Rate: 0.028, Accuracy: 72.62%
Epoch 20/25, Learning Rate: 0.024, Accuracy: 73.21%
Epoch 21/25, Learning Rate: 0.020, Accuracy: 74.40%
Epoch 22/25, Learning Rate: 0.016, Accuracy: 73.81%
Epoch 23/25, Learning Rate: 0.012, Accuracy: 73.81%
Epoch 24/25, Learning Rate: 0.008, Accuracy: 73.81%
Epoch 25/25, Learning Rate: 0.004, Accuracy: 74.40%


Fold 4 Accuracy: 64.29%



Fold 5

Epoch 1/25, Learning Rate: 0.100, Accuracy: 47.62%
Epoch 2/25, Learning Rate: 0.096, Accuracy: 62.50%
Epoch 3/25, Learning Rate: 0.092, Accuracy: 63.69%
Epoch 4/25, Learning Rate: 0.088, Accuracy: 64.88%
Epoch 5/25, Learning Rate: 0.084, Accuracy: 68.45%
Epoch 6/25, Learning Rate: 0.080, Accuracy: 70.83%
Epoch 7/25, Learning Rate: 0.076, Accuracy: 70.83%
Epoch 8/25, Learning Rate: 0.072, Accuracy: 72.02%
Epoch 9/25, Learning Rate: 0.068, Accuracy: 73.21%
Epoch 10/25, Learning Rate: 0.064, Accuracy: 73.21%
Epoch 11/25, Learning Rate: 0.060, Accuracy: 75.60%
Epoch 12/25, Learning Rate: 0.056, Accuracy: 75.60%
Epoch 13/25, Learning Rate: 0.052, Accuracy: 76.79%
Epoch 14/25, Learning Rate: 0.048, Accuracy: 75.60%
Epoch 15/25, Learning Rate: 0.044, Accuracy: 76.79%
Epoch 16/25, Learning Rate: 0.040, Accuracy: 75.60%
Epoch 17/25, Learning Rate: 0.036, Accuracy: 76.79%
Epoch 18/25, Learning Rate: 0.032, Accuracy: 76.79%
Epoch 19/25, Learning Rate: 0.028, Accuracy: 76.19%
Epoch 20/25, Learning Rate: 0.024, Accuracy: 75.60%
Epoch 21/25, Learning Rate: 0.020, Accuracy: 76.19%
Epoch 22/25, Learning Rate: 0.016, Accuracy: 76.19%
Epoch 23/25, Learning Rate: 0.012, Accuracy: 77.38%
Epoch 24/25, Learning Rate: 0.008, Accuracy: 77.38%
Epoch 25/25, Learning Rate: 0.004, Accuracy: 77.38%

Fold 5 Accuracy: 71.43%



Proses Pelatihan:

Pada setiap fold, model LVQ dilatih selama 25 epoch. Setiap epoch menyesuaikan subset representatif dari data latih, dan akurasi model dievaluasi. Learning rate berkurang secara bertahap pada setiap epoch, mulai dari 0.1 dan berakhir di sekitar 0.004 pada epoch ke-25.

Performa Pelatihan:

Berikut adalah akurasi yang dicapai pada setiap epoch untuk masing-masing fold:

Fold 1:

- Akurasi mulai dari 48.81% pada epoch 1 dan meningkat secara bertahap hingga mencapai 77.38% pada epoch 25.
- Akurasi cenderung stabil dan meningkat dengan learning rate yang menurun.

Fold 2:

- Akurasi mulai dari 31.55% pada epoch 1 dan mencapai 75.60% pada epoch 25, dengan puncak akurasi 79.17% pada epoch 11.
- Akurasi meningkat secara signifikan pada awal pelatihan dan stabil setelahnya.

Fold 3:

- Akurasi mulai dari 43.45% pada epoch 1 dan mencapai 71.43% pada epoch 25.
- Akurasi meningkat dengan stabil, menunjukkan pola peningkatan yang konsisten.

Fold 4:

- Akurasi mulai dari 37.50% pada epoch 1 dan mencapai 74.40% pada epoch 25.
- Akurasi menunjukkan peningkatan yang stabil dengan fluktuasi kecil.

Fold 5:

- Akurasi mulai dari 47.62% pada epoch 1 dan mencapai 77.38% pada epoch 25.
- Akurasi meningkat dengan pola yang konsisten, menunjukkan stabilitas model.

Akurasi Pengujian:

Akurasi setiap fold setelah pelatihan:

- Fold 1 Accuracy: 59.52%
- Fold 2 Accuracy: 78.57%
- Fold 3 Accuracy: 76.19%
- Fold 4 Accuracy: 64.29%
- Fold 5 Accuracy: 71.43%

Mean Accuracy: 70.00%

Evaluasi Model:

Model LVQ menunjukkan performa yang bervariasi di antara fold yang berbeda. Akurasi rata-rata 70.00% menunjukkan model cukup baik dalam mengklasifikasikan data pada set pengujian, meskipun ada variasi performa antara fold.

Kesimpulan:

- Stabilitas dan Konsistensi: Model menunjukkan peningkatan akurasi yang konsisten selama pelatihan dengan learning rate yang menurun. Ini menunjukkan bahwa model LVQ dapat belajar pola dalam data dengan efektif.
- Variasi Akurasi: Terdapat variasi akurasi antar fold yang menunjukkan bahwa performa model dapat dipengaruhi oleh distribusi data dalam fold yang berbeda.

Fold kedua memiliki akurasi tertinggi (78.57%) sedangkan fold pertama memiliki akurasi terendah (59.52%).

- Mean Accuracy: Akurasi rata-rata sebesar 70.00% adalah hasil yang cukup baik untuk model LVQ pada dataset ini, meskipun ada ruang untuk perbaikan.

G. Listing Program

```
import numpy as np
import pandas as pd
from random import randrange
from math import sqrt
from sklearn.preprocessing import StandardScaler
from sklearn.metrics import confusion_matrix,
ConfusionMatrixDisplay
import matplotlib.pyplot as plt

# Membaca dataset
path = "/content/drive/My Drive/UAS_JST/glass.csv"
df = pd.read_csv(path)

# Memisahkan fitur dan label
features = df.drop('Type', axis=1)
labels = df['Type'].values
labels = labels.reshape(len(labels), 1)

# Normalisasi fitur
scaler = StandardScaler()
features = scaler.fit_transform(features)

# Menggabungkan fitur dan label
dataset = np.append(features, labels, axis=1).tolist()

# Fungsi untuk K-Fold Cross-Validation
def kfold(dataset, n_folds):
    dataset_split = list()
    dataset_copy = list(dataset)
    fold_size = int(len(dataset) / n_folds)

    for i in range(n_folds):
        fold = list()
        while len(fold) < fold_size:
            index = randrange(len(dataset_copy))
            fold.append(dataset_copy.pop(index))
        dataset_split.append(fold)
```

```

        return dataset_split

n_folds = 5
folds = kfold(dataset, n_folds)

# Fungsi untuk menghitung jarak Euclidean
def euclidean_distance(row1, row2):
    distance = 0.0
    for i in range(len(row1)-1):
        distance += (row1[i] - row2[i])**2
    return sqrt(distance)

# Fungsi untuk memilih subset secara acak
def random_subset(train):
    n_records = len(train)
    n_features = len(train[0])
    subsets = [train[randrange(n_records)][i] for i in
range(n_features)]
    return subsets

# Fungsi untuk menemukan best match unit (BMU)
def best_match(subsets, test_row):
    distances = list()
    for subset in subsets:
        dist = euclidean_distance(subset, test_row)
        distances.append((subset, dist))
    distances.sort(key=lambda tup: tup[1])
    return distances[0][0]

# Fungsi untuk model LVQ dengan penambahan output akurasi
setiap epoch
def lvq(train_set, n_subsets, lrate, epochs):
    subsets = [random_subset(train_set) for i in
range(n_subsets)]
    for epoch in range(epochs):
        rate = lrate * (1.0 - (epoch / float(epochs)))
        correct = 0
        for row in train_set:
            bmu = best_match(subsets, row)
            for i in range(len(row) - 1):
                error = row[i] - bmu[i]
                if bmu[-1] == row[-1]:
                    bmu[i] += rate * error
                else:
                    bmu[i] -= rate * error
            if bmu[-1] == row[-1]:
                correct += 1
        accuracy = correct / float(len(train_set)) * 100.0

```

```

        print(f'Epoch {epoch + 1}/{epochs}, Learning Rate:
{rate:.3f}, Accuracy: {accuracy:.2f}%')
    return subsets

# Fungsi untuk menghitung akurasi
def accuracy(actual, predicted):
    correct = 0
    for i in range(len(actual)):
        if actual[i] == predicted[i]:
            correct += 1
    return correct / float(len(actual)) * 100.0

# Fungsi untuk membagi data latih dan data uji
def train_test_split(folds, fold_index):
    train_set = list(folds)
    test_set = train_set.pop(fold_index)
    train_set = sum(train_set, [])
    return train_set, test_set

# Parameter model
lrate = 0.1
epochs = 25
n_subsets = 50
n_folds = 5

# Menampilkan parameter yang digunakan
print("Parameter:")
print(f"Learning Rate: {lrate}")
print(f"Epochs: {epochs}")
print(f"Number of Subsets: {n_subsets}")
print(f"Number of Folds: {n_folds}")

scores = list()
confusion_matrices = []

# Proses K-Fold Cross-Validation
for fold_index, fold in enumerate(folds):
    print(f'\nFold {fold_index + 1}')
    train_set, test_set = train_test_split(folds, fold_index)
    subsets = lvq(train_set, n_subsets, lrate, epochs)

    y_hat = list()
    for test_row in test_set:
        output = best_match(subsets, test_row)
        y_hat.append(output[-1])

    y_true = [row[-1] for row in test_set]
    fold_accuracy = accuracy(y_true, y_hat)

```

```

scores.append(fold_accuracy)

# Confusion Matrix
cm = confusion_matrix(y_true, y_hat,
labels=np.unique(labels))
confusion_matrices.append(cm)

# Tampilkan akurasi setiap fold
print(f'Fold {fold_index + 1} Accuracy:
{fold_accuracy:.2f}%')

# Menghitung dan menampilkan rata-rata akurasi
mean_accuracy = np.mean(scores)
print(f'\nMean Accuracy: {mean_accuracy:.2f}%')

# Visualisasi Confusion Matrix untuk setiap fold
for fold_index, cm in enumerate(confusion_matrices):
    disp = ConfusionMatrixDisplay(confusion_matrix=cm,
display_labels=np.unique(labels))
    disp.plot(cmap=plt.cm.Blues)
    plt.title(f'Confusion Matrix for Fold {fold_index + 1}')
    plt.show()

```

H. Referensi

<https://www.kaggle.com/code/alincijov/glass-classification-lvq-from-scratch>

Fausett, L. (1994). Fundamentals of Neural Networks: Architectures, Algorithms, and Applications. Englewood Cliffs, New Jersey: Prentice Hall

Larandipa, L.A., W, F.T.P. and Triyanto, D. (2013) 'Aplikasi Jaringan Syaraf Tiruan Untuk Diagnosa Penyakit Jantung Koroner (PJK) Dengan Metode Backpropagation', *Coding Sistem Komputer Universitas Tanjungpura*, 01(1), pp. 11–19.

Rahayu, N.M.Y.D., Antara Kesiman, M.W. and Gunadi, I.G.A. (2021) 'Identifikasi Jenis Kayu Berdasarkan Fitur Tekstur Local Binary Pattern Menggunakan Metode Learning Vector Quantization', *Jurnal Nasional Pendidikan Teknik Informatika (JANAPATI)*, 10(3), p. 157. doi:10.23887/janapati.v10i3.40804.