

LAPORAN PROYEK AKHIR DATA MINING

Analisis Segmentasi Pelanggan untuk Pemegang Kartu Kredit dengan Hierarchical Clustering



Disusun oleh:

Duli Tabita Sagala	(21309141013)
Syarafina Fajri	(21309141027)
Oktavian Rahmat Pamungkas	(21309141030)
Muhammad Nasiruddin Al Bani	(21309144019)

Dosen Pengampu:

Nur Hadi Waryanto, S.Si., M.Eng.

**PROGRAM STUDI S1 STATISTIKA
DEPARTEMEN PENDIDIKAN MATEMATIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS NEGERI YOGYAKARTA YOGYAKARTA
2023**

A. Ringkasan Studi Kasus

Judul Studi Kasus	Analisis Segmentasi Pelanggan untuk Pemegang Kartu Kredit dengan Hierarchical Clustering
Deskripsi Singkat Studi Kasus	Analisis Segmentasi Pelanggan untuk Pemegang Kartu Kredit dengan Hierarchical Clustering merupakan studi yang bertujuan untuk mengelompokkan pelanggan berdasarkan perilaku penggunaan kartu kredit menggunakan metode hierarchical clustering. Dataset mencakup sekitar 8651 pemegang kartu kredit aktif selama 6 bulan terakhir dengan 18 variabel perilaku, seperti jumlah pembelian, frekuensi pembelian, dan limit kredit. Melalui pendekatan hierarchical clustering, penelitian ini bertujuan untuk mengidentifikasi pola perilaku yang serupa di antara pelanggan dan membentuk segmentasi yang relevan. Analisis ini dapat memberikan wawasan strategis bagi perusahaan kartu kredit dalam merancang strategi pemasaran yang lebih efektif dan disesuaikan dengan kebutuhan setiap segmen pelanggan. Berikut variabel-variabel yang terdapat pada dataset.
Bahasa Pemrograman yang Digunakan	Python
Sumber Data	https://www.kaggle.com/datasets/arjunbhasin2013/ccdata
Jenis Data	Sekunder
Link Video	https://drive.google.com/drive/folders/11DrrJZqiVpTcjk7x8gjxhkXRieogMgo?usp=drive_link

B. Deskripsi Studi Kasus

Permasalahan: Membuat segmentasi atau pembagian customer untuk menentukan strategi pemasaran.

Analisis Segmentasi Pelanggan untuk Pemegang Kartu Kredit dengan Hierarchical Clustering merupakan studi yang bertujuan untuk mengelompokkan pelanggan berdasarkan perilaku penggunaan kartu kredit menggunakan metode hierarchical clustering. Dataset mencakup sekitar 8651 pemegang kartu kredit aktif selama 6 bulan terakhir dengan 18 variabel perilaku, seperti jumlah pembelian, frekuensi pembelian, dan limit kredit. Melalui pendekatan hierarchical clustering, penelitian ini bertujuan untuk mengidentifikasi pola perilaku yang serupa di antara pelanggan dan membentuk segmentasi yang relevan. Analisis ini dapat memberikan wawasan strategis bagi perusahaan kartu kredit dalam merancang strategi pemasaran yang lebih efektif dan disesuaikan dengan kebutuhan setiap segmen pelanggan. Berikut variabel-variabel yang terdapat pada dataset.

Variabel:

1. CUSTID: ID pemilik kartu kredit (data kategorikal)
2. BALANCE: Jumlah uang yang tersisa di kartu kredit
3. BALANCEFREQUENCY: Menyatakan seberapa sering pengguna memperbarui balance kartu kredit (melakukan top up/menambahkan deposit/memasukkan uang ke kartu kredit). Nilainya antara 0-1 dimana 1 adalah balance sering diperbarui dan 0 adalah balance tidak sering diperbarui
4. PURCHASE: Total nominal transaksi pembelian seorang pengguna (dalam waktu 6 bulan)
5. ONEOFFPURCHASE: Nominal maksimal transaksi pembelian yang dilakukan dengan satu kali pembayaran
6. INSTALLMENTPURCHASE: Total nominal transaksi pembelian yang dilakukan dengan cara cicilan
7. CASHADVANCE: Total nominal uang cash yang ditarik dari kartu kredit (seperti ATM, bukan untuk membayar transaksi pembelian)
8. PURCHASESFREQUENCY: Seberapa sering transaksi dilakukan, nilainya antara 0-1 dimana 1=sering melakukan transaksi dan 0=tidak sering melakukan transaksi
9. ONEOFFPURCHASEFREQUENCY: Seberapa sering dilakukan transaksi pembelian dengan satu kali pembayaran, nilainya antara 0-1 dimana 1=sering dan 0=tidak sering
10. PURCHASEINSTALLMENTSFREQUENCY: Seberapa sering memilih metode pembayaran dengan cicilan, nilainya antara 0-1 dimana 1=sering dan 0=tidak sering
11. CASHADVANCEFREQUENCY: Seberapa sering melakukan penarikan uang, nilainya antara 0-1 dimana 1=sering dan 0=tidak sering

12. CASHADVANCETRX: Banyak melakukan pengambilan uang (contoh: 2 kali, 5 kali, dst)
13. PURCHASETRX: Banyak melakukan transaksi pembelian
14. CREDITLIMIT: Batas nominal maksimal kartu kredit
15. PAYMENTS: Total nominal pelunasan cicilan kartu kredit pengguna
16. MINIMUMPAYMENTS: Batas pembayaran minimal untuk melakukan pelunasan kartu kredit
17. PRCFULLPAYMENT: Persentase pengguna melunasi kartu kredit dengan menggunakan pembayaran penuh
18. TENURE: Jangka waktu kartu kredit

C. Landasan Teori

a. Persiapan Data (*Preprocessing*)

Datasests yan digunakan adalah datasets dari Kaggle. banyaknya record data yang akan digunakan pada penelitian inni sebanyak 8651 pemegang kartu kredit aktif selama 6 bulan terakhir dengan 18 variabel perilaku, seperti jumlah pembelian, frekuensi pembelian, dan limit kredit.

Agar datasests dapat digunakan untuk Hierarchical clustering harus dibersihkan terlebih dahulu dari *Missing Value* dengan cara di isi menggunakan rata - rata dari masing - masing variabel. selanjutnya, dilakukan standarisasi pada nilai data untuk menyeragamkan nilai data.

b. Clustering

Pengelompokan (clustering) adalah bagian dari data mining yang bersifat tanpa arahan (unsupervised). Clustering merupakan suatu proses pembagian data ke dalam kelas atau disebut cluster yang berdasarkan tingkat kemiripan. Dalam clustering, data-data yang mempunyai kemiripan digabungkan kedalam cluster yang sama, begitu juga sebaliknya data yang tidak mempunyai kemiripan akan dimasukkan dalam cluster yang berbeda

Analisis cluster adalah metode yang tepat untuk mengidentifikasi objek-objek yang homogen ke dalam kelompok-kelompok yang disebut cluster. Cluster-cluster yang terbentuk memiliki homogenitas internal yang tinggi dan heterogenitas eksternal yang tinggi(Hair,dkk., 2010:486). Metode clustering dibagi menjadi dua, yaitu: metode clustering hirarki dan metode clustering nonhirarki.

Clustering dengan pendekatan hirarki akan mengelompokkan data yang mirip dalam hirarki yang sama dan yang tidak mirip di hirarki yang agak jauh. Hierarchical clustering ada dua, yaitu divisive (top to down) dan agglomerative (down to top). Agglomerative melakukan clustering dari n cluster menjadi satu kesatuan cluster, dimana N adlah jumlah data, sebaliknya divisive melakukan proses clustering dari satu cluster menjadi N cluster(Everitt, Landau, Leese, & Stahl, 2011).

Dalam penelitian ini, kami menggunakan Clustering hirarki dengan metode agglomerative,yang dapat direpresentasikan dengan diagram dua

dimensi, yaitu dendogram. Dendogram ini mengilustrasikan penyatuan pada masing-masing tahap dalam analisis (Everitt,dkk, 2011:72).

Algoritma agglomerative ada empat yaitu single linkage, complete linkage, average linkage dan ward. Dalam penelitian ini menggunakan metode Ward. Salah satu algoritma agglomerative sebagai algoritma dalam penelitian ini adalah Ward.

c. Koefisien Silhouette

Koefisien Silhouette atau Silhouette Index merupakan metode untuk mengukur validasi baik sebuah data, cluster tunggal atau keseluruhan cluster. Nilai Koefisien Silhouette data ke-i berdasarkan dua komponen yaitu a_i dan b_i . Komponen a_i adalah jarak dari data ke-i terhadap semua data dalam cluster yang sama. Sedangkan komponen b_i adalah rata-rata jarak data ke-i terhadap semua data dari cluster lain(Prasetyo,2012).

Berikut adalah rumus menghitung komponen a_i

$$a_i^j = \frac{1}{m_j-1} \sum_{\substack{r=1 \\ r \neq i}}^{m_j} d(x_i^j, x_r^j), i = 1, 2, \dots, m_j$$

Dimana :

j = cluster

i = index data

a_i^j = rata-rata jarak ke-i terhadap semua data lainnya dalam satu cluster

m_j = jumlah data dalam cluster ke-j

$d(x_i^j, x_r^j)$ = jarak data ke-i dengan data ke-r dalam satu cluster j

Berikut rumus menghitung komponen b_i :

$$b_i^j = \min_{n \neq j} \left\{ \frac{1}{m_n} \sum_{\substack{r=1 \\ r \neq i}}^{m_n} d(x_i^j, x_r^n) \right\}, i = 1, 2, \dots, m_j$$

Dimana :

j = cluster

n = cluster

i = index data

m_n = banyak data dalam satu cluster

b_i^j = nilai terkecil dari rata-rata jarak data ke-i terhadap semua data dari cluster yang lain tidak dalam satu cluster dengan data ke-i

Untuk menghitung Koefisien Silhouette data ke-i menggunakan persamaan berikut ini:

$$S_i^j = \frac{b_i^j - a_i^j}{\max\{b_i^j, a_i^j\}}$$

Dimana:

S_i^j = Koefisien *Silhouette* data ke- i dalam satu *cluster*

a_j^i = rata-rata jarak ke- i terhadap semua data lain dalam satu *cluster*

b_i^j = nilai terkecil dari rata-rata jarak data ke- i terhadap semua data dari *cluster* yang lain tidak dalam satu *cluster* dengan data ke- i

d. Metode Ward

Metode Ward merupakan metode varians yang bertujuan untuk memperoleh *cluster* yang memiliki varians *cluster* terkecil. Metode varians yang umum dipakai adalah metode ward dimana rata - rata untuk setiap kelompok dihitung. perhitungan jarak ini menggunakan *Squared Euclidian* pada antar setiap objek sebagai berikut :

$$d_{(xy)z} = \frac{(n_x + n_z)d_{xz} + (n_y + n_z)d_{yz} - n_z d_{xy}}{n_x + n_y + n_z}$$

Dengan,

n_x : Jumlah objek pada cluster x

n_y : Jumlah objek pada cluster y

n_z : Jumlah objek pada cluster z

d_{xz} : Jarak antara cluster x dan cluster z

d_{yz} : Jarak antara cluster y dan cluster z

d_{xy} : Jarak antara cluster x dan cluster z

e. *Principal Component Analysis* (PCA)

Metode Karhunen - Loeve adalah metode statistik multi-variabel umum dimana PCA digunakan untuk ekstraksi fitur dan pengurangan dimensi dalam analisis pola. tujuannya untuk mengekstraksi informasi penting dari data dan mengurangi volume kumpulan data dengan mempertahankan informasi penting dan menjelaskan kumpulan data masukan ($X = [x_1, x_2, \dots, x_n]$) dimana setiap kolom adalah pola masukan - dimensi. Asumsikan lebih lanjut bahwa rata - rata setiap fitur dalam kumpulan data sama dengan nol ($E(X)=0$). Transformasi ortonormal dapat digunakan untuk memetakan X ke ruang baru Y sebagai:

$$Y = AX$$

Assuming that $E(X)=0$, the $E(Y)=0$ and Y covariance matrix

$$R_Y = AR_X A^T$$

dimana R_X adalah matriks kovarian dari X . jika barisan A adalah vektor eigen dari R_X , lalu dengan menggunakan transformasi ini, sampel menjadi tidak berkorelasi di ruang baru, jelas bahwa sampelnya adalah dimensi dalam ruang fitur (yang dipetakan); namun, tujuan transformasi PCA adalah untuk menciptakan $k < d$ sampel yang dipetakan dimensi yang akan diperkirakan sehat. menggunakan persamaan (1) dapat dibuat ulang sebagai $X=A^T Y$. bukannya bereproduksi menggunakan seluruh vektor eigen, dapat diperkirakan dengan vektor eigen yang lebih sedikit; dengan demikian dimana $X=A^T Y$. k vektor eigen digunakan. dalam hal ini, *Mean Square Error* (MSE) yang dihasilkan adalah:

$$err = \sum_{i=1}^d \lambda_i - \sum_{i=1}^k \lambda_i = \sum_{i=k+1}^d \lambda_i.$$

D. Penyelesaian dan Pembahasan

Tahapan dalam Hierarchical Clustering untuk pemegang kartu kredit:

1. Mempersiapkan dataset

Pada studi kasus ini dataset diambil dari data sekunder yang bersumber dari <https://www.kaggle.com/datasets/arjunbhasin2013/ccdata>.

2. Mengimport library-library yang dibutuhkan dalam proses coding

Library yang digunakan:

- a. Numpy: untuk mengolah data yang berbentuk array dan melakukan komputasi
- b. Pandas: digunakan untuk membaca file csv dan menampilkan data dalam bentuk tabel
- c. Seaborn: digunakan untuk melakukan plot variabel dalam bentuk diagram batang
- d. AgglomerativeClustering, dendrogram, dan linkage: digunakan untuk hierarchical clustering
- e. Silhouette score: digunakan untuk mengukur kualitas cluster yang terbentuk
- f. StandardScaler: digunakan untuk melakukan preprocessing yaitu menyeragamkan nilai data
- g. PCA dan cosine similarity: digunakan untuk reduksi fitur data sehingga dapat dilakukan visualisasi 2 dimensi

3. Mengimport dataset

4. Preprocessing Data:

a. Menghapus kolom “CUST_ID”

Pada dataset, terdapat fitur “CUST_ID” yang tidak diperlukan dalam melakukan clustering sehingga kolom tersebut dihapus.

b. Melakukan pengecekan apakah terdapat data yang kosong (memiliki missing values)

Setelah dilakukan pengecekan pada dataset “Credit Card” terdapat 313 nilai kosong pada “MINIMUM_PAYMENTS” dan 1 nilai kosong pada “CREDIT_LIMIT”.

c. Melakukan preprocessing pada nilai yang kosong

Nilai yang kosong pada kedua fitur yang memiliki nilai kosong diisi dengan nilai rata-rata dari fitur tersebut.

d. Menyeragamkan rentang nilai pada tiap-tiap fitur atau kolom pada dataset

Pada tahap ini digunakan fungsi StandardScaler untuk memetakan nilai data yang baru berdasarkan perhitungan nilai rata-rata dan variansi dari tiap-tiap kolom atau fitur. Jika nilai data tidak diseragamkan, kolom yang rentangnya 0-tak terhingga akan dianggap jauh lebih penting daripada yang rentangnya 0-1.

5. Visualisasi Dendrogram

Dilakukan hierarki data yang divisualisasikan dalam bentuk dendrogram. Hierarki ini menghubungkan data-data yang jaraknya dekat sebagai satu cluster hingga yang paling atas adalah garis yang menghubungkan dua buah cluster yang tersisa.

Karena dataset terdiri dari 9000 data, dilakukan pemangkasan data yang ditampilkan dalam option “truncated_mode=none”. Jika tidak dilakukan pemangkasan data, maka akan divisualisasi terhadap seluruh data.

6. Menentukan jumlah cluster terbaik

Untuk menentukan jumlah cluster terbaik, digunakan Silhouette score. Dilakukan perhitungan Silhouette score untuk jumlah cluster 2 hingga 10. Semakin tinggi nilai Silhouette score, maka semakin baik cluster yang terbentuk, disini yang terbaik adalah jumlah cluster 2. Hasil clustering dikatakan baik apabila data-data di dalam satu cluster berbeda jauh dengan data-data di cluster lainnya. Namun pada studi kasus ini, dilakukan clustering menggunakan metode hierarchical clustering dengan jumlah cluster 3.

7. Melakukan clustering data menggunakan Agglomerative Clustering

Dilakukan clustering menggunakan metode agglomerative dengan jumlah cluster 3.


8. Melakukan visualisasi frekuensi nilai suatu fitur dari masing-masing cluster

Tahap selanjutnya adalah melakukan visualiasi pada masing-masing fitur untuk melihat frekuensi nilai suatu fitur dari ketiga cluster.


9. Melakukan visualisasi cluster menggunakan scatter plot
 Karena scatter plot digambarkan pada bidang 2 dimensi, maka hanya bisa mengakomodasi data dengan 2 fitur (untuk sumbu X dan Y) sedangkan data yang digunakan memiliki 17 buah fitur. Oleh karena itu, perlu dilakukan reduksi dimensi data dari 17 menjadi 2 menggunakan metode PCA (Principal Component Analysis). Setelah terbentuk data baru dengan 2 buah fitur, dilakukan pewarnaan dan pelabelan pada cluster.

E. Hasil Penyelesaian

1. Visualisasi dendrogram



2. Silhouette score



Semakin tinggi nilai Silhouette score, maka semakin baik cluster yang terbentuk, disini yang terbaik adalah jumlah cluster 2. Namun pada studi kasus ini, dilakukan clustering menggunakan metode hierarchical clustering dengan jumlah cluster 3.

3. Clustering data (Agglomerative Clustering)


	BALANCE	BALANCE_FREQUENCY	PURCHASES	ONEOFF_PURCHASES	INSTALLMENTS_PURCHASES	CASH_ADVANCE	PURCHASES_FREQUENCY	ONEOFF_PURCHASES_FREQUENCY	PURCHASES_INSTALLMENTS_FREQUENCY
0	-0.731989	-0.249434	-0.424900	-0.356934	-0.349079	-0.466786	-0.806490	-0.678661	-0.707313
1	0.786961	0.134325	-0.469552	-0.356934	-0.454576	2.605605	-1.221758	-0.678661	-0.916995
2	0.447135	0.518084	-0.107668	0.108889	-0.454576	-0.466786	1.269843	2.673451	-0.916995
3	0.049099	-1.016953	0.232058	0.546189	-0.454576	-0.368653	-1.014125	-0.399319	-0.916995
4	-0.358775	0.518084	-0.462063	-0.347294	-0.454576	-0.466786	-1.014125	-0.399319	-0.916995

CASH_ADVANCE_FREQUENCY	CASH_ADVANCE_TRX	PURCHASES_TRX	CREDIT_LIMIT	PAYMENTS	MINIMUM_PAYMENTS	PRC_FULL_PAYMENT	TENURE	cluster
-0.675349	-0.476070	-0.511333	-0.960433	-0.528979	-3.109675e-01	-0.525551	0.36068	1
0.573963	0.110074	-0.591796	0.688639	0.818642	8.931021e-02	0.234227	0.36068	2
-0.675349	-0.476070	-0.109020	0.826062	-0.383805	-1.016632e-01	-0.525551	0.36068	0
-0.258913	-0.329534	-0.551565	0.826062	-0.598688	4.878305e-17	-0.525551	0.36068	1
-0.675349	-0.476070	-0.551565	-0.905464	-0.364368	-2.657913e-01	-0.525551	0.36068	1

Pada hasil clustering didapatkan:

- Jumlah data pada cluster 0:3418
- Jumlah data pada cluster 1:4668
- Jumlah data pada cluster 2:864


4. Visualisasi frekuensi nilai suatu fitur pada masing-masing cluster



Nilai frekuensi pada fitur Balance

- Cluster 0: fitur balance paling banyak (2500 buah) nilainya berada diantara -1 hingga 0
- Cluster 1: fitur balance paling banyak (3000 buah) bernilai dibawah 0
- Cluster 2: fitur balance nilainya tersebar rata dari -1 hingga 6

5. Visualisasi Scatter Plot



Berikut penjelasan dari plot:

- Warna merah menunjukkan cluster 0
- Warna biru menunjukkan cluster 1
- Warna hijau menunjukkan cluster 2

Dari hasil clustering tersebut, dapat diambil masukan untuk strategi pemasaran yaitu:

- a. Tinggi saldo, tinggi pembelian (cluster 0)
Pelanggan pada cluster ini melakukan pembelian mahal tetapi juga memiliki saldo yang lebih tinggi untuk mendukung pembelian tersebut. Mereka juga melakukan pembayaran besar dan dapat menjadi target pemasaran. Cluster ini direpresentasikan oleh warna merah pada scatter plot.
- b. Saldo menengah, pembelian menengah (cluster 2)
Pelanggan pada cluster ini tidak memiliki saldo rendah atau tinggi dan mereka juga tidak melakukan pembelian besar atau kecil tetapi melakukan segalanya dalam tingkat menengah. Pelanggan pada cluster ini dipresentasikan oleh warna hijau pada scatter plot.
- c. Pelanggan hemat atau saldo rendah, pembelian rendah (cluster 1)
Pada cluster ini pelanggan yang melakukan pembelian terkecil dan karena batas kredit mereka juga rendah, ini berarti bahwa pelanggan tidak melakukan pembelian secara sering. Oleh karena itu, dapat diasumsikan bahwa pelanggan ini berhenti dan strategi pemasaran dapat dirancang untuk menargetkan pelanggan ini. Pelanggan pada cluster ini adalah kelompok terkecil dan dipresentasikan oleh warna biru dalam scatter plot.

F. Output Program

1) IMPORT PACKAGE PYTHON

```
# ===== IMPORT LIBRARY =====
```

```

import numpy as np    #mengolah data yang berbentuk array
import pandas as pd   #membaca file csv dan display dalam bentuk
tabel
import matplotlib.pyplot as plt  #digunakan untuk visualisasi
data
from scipy.sparse import data

# ===== Membuat Plot dalam Bentuk Diagram Batang =====
import seaborn as sns
from sklearn.cluster import AgglomerativeClustering
from scipy.cluster.hierarchy import dendrogram, linkage

# ===== Silhouette Score =====
from sklearn.metrics import silhouette_score    #digunakan untuk
mengukur kualitas cluster yang terbentuk

# ===== Standard Scaler =====
#untuk melakukan preprocessing, menyeragamkan rentang nilai data
pada dataset
from sklearn.preprocessing import StandardScaler

# Fungsi untuk reduksi fitur data sehingga dapat dilakukan
visualisasi 2 dimensi
from sklearn.decomposition import PCA
from sklearn.metrics.pairwise import cosine_similarity

```

2) IMPORT DATASET

```

dataset=pd.read_csv('CC GENERAL.csv')
print(dataset)

```

	CUST_ID	BALANCE	BALANCE_FREQUENCY	PURCHASES
ONEOFF_PURCHASES \				
0	C10001	40.900749	0.818182	95.40
0.00				
1	C10002	3202.467416	0.909091	0.00
0.00				
2	C10003	2495.148862	1.000000	773.17
773.17				
3	C10004	1666.670542	0.636364	1499.00
1499.00				
4	C10005	817.714335	1.000000	16.00
16.00				
...	...	...	...	...
...				
8945	C19186	28.493517	1.000000	291.12
0.00				

8946	C19187	19.183215	1.000000	300.00
0.00				
8947	C19188	23.398673	0.833333	144.40
0.00				
8948	C19189	13.457564	0.833333	0.00
0.00				
8949	C19190	372.708075	0.666667	1093.25
1093.25				

	INSTALLMENTS_PURCHASES	CASH_ADVANCE	PURCHASES_FREQUENCY
\			
0	95.40	0.000000	0.166667
1	0.00	6442.945483	0.000000
2	0.00	0.000000	1.000000
3	0.00	205.788017	0.083333
4	0.00	0.000000	0.083333
...	...	...	...
8945	291.12	0.000000	1.000000
8946	300.00	0.000000	1.000000
8947	144.40	0.000000	0.833333
8948	0.00	36.558778	0.000000
8949	0.00	127.040008	0.666667

ONEOFF_PURCHASES_FREQUENCY	PURCHASES_INSTALLMENTS_FREQUENCY	\
0	0.000000	
0.083333		
1	0.000000	
0.000000		
2	1.000000	
0.000000		
3	0.083333	
0.000000		
4	0.083333	
0.000000		
...	...	
...		
8945	0.000000	
0.833333		
8946	0.000000	
0.833333		
8947	0.000000	
0.666667		
8948	0.000000	
0.000000		
8949	0.666667	
0.000000		

CASH_ADVANCE_FREQUENCY	CASH_ADVANCE_TRX	PURCHASES_TRX
CREDIT_LIMIT	\	

0	0.000000	0	2
1000.0			
1	0.250000	4	0
7000.0			
2	0.000000	0	12
7500.0			
3	0.083333	1	1
7500.0			
4	0.000000	0	1
1200.0			
...	...	...	...
...			
8945	0.000000	0	6
1000.0			
8946	0.000000	0	6
1000.0			
8947	0.000000	0	5
1000.0			
8948	0.166667	2	0
500.0			
8949	0.333333	2	23
1200.0			

	PAYMENTS	MINIMUM_PAYMENTS	PRC_FULL_PAYMENT	TENURE
0	201.802084	139.509787	0.000000	12
1	4103.032597	1072.340217	0.222222	12
2	622.066742	627.284787	0.000000	12
3	0.000000	NaN	0.000000	12
4	678.334763	244.791237	0.000000	12
...	...	...	...	...
8945	325.594462	48.886365	0.500000	6
8946	275.861322	NaN	0.000000	6
8947	81.270775	82.418369	0.250000	6
8948	52.549959	55.755628	0.250000	6
8949	63.165404	88.288956	0.000000	6

[8950 rows x 18 columns]

3) PREPROCESSING DATA

```
# Menghapus kolom cust_id
```

```
dataset.drop('CUST_ID', axis = 1, inplace = True)
```

```
# Pengecekan nilai null (kosong) pada dataset
```

```
dataset.isnull().sum().sort_values(ascending=False).head()
```

```
MINIMUM_PAYMENTS      313
```

```
CREDIT_LIMIT           1
```

```
BALANCE                0
```

```
CASH_ADVANCE_FREQUENCY 0
```

```
PRC_FULL_PAYMENT       0
```

```
dtype: int64
```

Terdapat 313 nilai null (kosong) pada variabel MINIMUM_PAYMENTS dan 1 nilai null (kosong) pada variabel CREDIT_LIMIT

```
# Mengisi nilai null dengan nilai rata-rata pada kolom tersebut
dataset['CREDIT_LIMIT'] =
dataset['CREDIT_LIMIT'].fillna(dataset['CREDIT_LIMIT'].mean())
dataset['MINIMUM_PAYMENTS'] =
dataset['MINIMUM_PAYMENTS'].fillna(dataset['MINIMUM_PAYMENTS'].mean())

len(dataset.columns[dataset.isnull().any()])
dataset.isnull().sum().sort_values(ascending=False).head()
BALANCE                                0
CASH_ADVANCE_FREQUENCY                0
PRC_FULL_PAYMENT                      0
MINIMUM_PAYMENTS                     0
PAYMENTS                             0
dtype: int64
```

Setelah dilakukan pengisian nilai menggunakan nilai rata-rata, maka semua kolom sudah terisi dan tidak ada kolom yang nilainya null (kosong)

```
# Standarisasi nilai
scaler = StandardScaler()
scaled_data = scaler.fit_transform(dataset)

df = pd.DataFrame(scaled_data, columns=dataset.columns)
df.head()
```

	BALANCE	BALANCE_FREQUENCY	PURCHASES	ONEOFF_PURCHASES	INSTALLMENTS_PURCHASES	CASH_ADVANCE	PURCHASES_FREQUENCY	ONEOFF_PURCHASES_FREQUENCY	PURCHASES_INSTALLMENTS_FREQUENCY
0	-0.731989	-0.249434	-0.424900	-0.356934	-0.349079	-0.466786	-0.806490	-0.678661	-0.707313
1	0.786961	0.134325	-0.469552	-0.356934	-0.454576	2.605605	-1.221758	-0.678661	-0.916995
2	0.447135	0.518084	-0.107668	0.108889	-0.454576	-0.466786	1.269843	2.673451	-0.916995
3	0.049099	-1.016953	0.232058	0.546189	-0.454576	-0.368653	-1.014125	-0.399319	-0.916995
4	-0.358775	0.518084	-0.462063	-0.347294	-0.454576	-0.466786	-1.014125	-0.399319	-0.916995


	CASH_ADVANCE_FREQUENCY	CASH_ADVANCE_TRX	PURCHASES_TRX	CREDIT_LIMIT	PAYMENTS	MINIMUM_PAYMENTS	PRC_FULL_PAYMENT	TENURE
	-0.675349	-0.476070	-0.511333	-0.960433	-0.528979	-3.109675e-01	-0.525551	0.36068
	0.573963	0.110074	-0.591796	0.688639	0.818642	8.931021e-02	0.234227	0.36068
	-0.675349	-0.476070	-0.109020	0.826062	-0.383805	-1.016632e-01	-0.525551	0.36068
	-0.258913	-0.329534	-0.551565	0.826062	-0.598688	4.878305e-17	-0.525551	0.36068
	-0.675349	-0.476070	-0.551565	-0.905464	-0.364368	-2.657913e-01	-0.525551	0.36068

4) PROCESSING DATA

```
# ===== VISUALISASI DATA =====
```



1. Diagram dendrogram

```
plt.figure(figsize=(15, 10))
dendrogram(linkage(df, method="ward"), leaf_rotation=90, p=5,
color_threshold=20, leaf_font_size=10, truncate_mode='level')
plt.show()
```



2. Silhouette score

```
silhouette_scores = []
for n_cluster in range(2, 10):
    silhouette_scores.append(
        silhouette_score(
            df, AgglomerativeClustering(n_clusters =
n_cluster).fit_predict(df)
        ) # Silhouette_score()
    ) # Silhouette_scores.append()
plt.bar(range(2, 10), silhouette_scores)
plt.xlabel('Jumlah cluster')
plt.ylabel('Silhouette Score')
plt.show()
```



3. Agglomerative clustering dengan jumlah cluster = 3

"""

Disini dilakukan clustering menggunakan metode Hierarchical Clustering dengan jumlah cluster 3.

"""

```
agglo = AgglomerativeClustering(n_clusters=3)
agglo.fit(df)
labels = agglo.labels_
hasil_agglo = pd.concat([df, pd.DataFrame({'cluster': labels})],
axis=1)
hasil_agglo.head()
```

	BALANCE	BALANCE_FREQUENCY	PURCHASES	ONEOFF_PURCHASES	INSTALLMENTS_PURCHASES	CASH_ADVANCE	PURCHASES_FREQUENCY	ONEOFF_PURCHASES_FREQUENCY	PURCHASES_INSTALLMENTS_FREQUENCY	
0	-0.731989	-0.249434	-0.424900	-0.356934	-0.349079	-0.466786	-0.806490	-0.678661	-0.707313	
1	0.786961	0.134325	-0.469552	-0.356934	-0.454576	2.605605	-1.221758	-0.678661	-0.916995	
2	0.447135	0.518084	-0.107668	0.108889	-0.454576	-0.466786	1.269843	2.673451	-0.916995	
3	0.049099	-1.016953	0.232058	0.546189	-0.454576	-0.368653	-1.014125	-0.399319	-0.916995	
4	-0.358775	0.518084	-0.462063	-0.347294	-0.454576	-0.466786	-1.014125	-0.399319	-0.916995	

CASH_ADVANCE_FREQUENCY	CASH_ADVANCE_TRX	PURCHASES_TRX	CREDIT_LIMIT	PAYMENTS	MINIMUM_PAYMENTS	PRC_FULL_PAYMENT	TENURE	cluster
-0.675349	-0.476070	-0.511333	-0.960433	-0.528979	-3.109675e-01	-0.525551	0.36068	1
0.573963	0.110074	-0.591796	0.688639	0.818642	8.931021e-02	0.234227	0.36068	2
-0.675349	-0.476070	-0.109020	0.826062	-0.383805	-1.016632e-01	-0.525551	0.36068	0
-0.258913	-0.329534	-0.551565	0.826062	-0.598688	4.878305e-17	-0.525551	0.36068	1
-0.675349	-0.476070	-0.551565	-0.905464	-0.364368	-2.657913e-01	-0.525551	0.36068	1

Memilih data berdasarkan kriteria

```
kondisi = (hasil_agglo['cluster'] == 0)
data_terpilih = hasil_agglo[kondisi]
```

```

jumlah_data = len(data_terpilih)
print(f'\njumlah data pada cluster 0:{jumlah_data}')

kondisi = (hasil_agglo['cluster'] == 1)
data_terpilih = hasil_agglo[kondisi]
jumlah_data1 = len(data_terpilih)
print(f'\njumlah data pada cluster 1:{jumlah_data1}')

kondisi = (hasil_agglo['cluster'] == 2)
data_terpilih = hasil_agglo[kondisi]
jumlah_data2 = len(data_terpilih)
print(f'\njumlah data pada cluster 2:{jumlah_data2}')

```

jumlah data pada cluster 0:3418

jumlah data pada cluster 1:4668

jumlah data pada cluster 2:864


4. Visualisasi hasil agglomerative clustering





""" Disini dilakukan visualisasi frekuensi nilai suatu fitur dari masing-masing cluster. """





```





for i in hasil_agglo:
    grid = sns.FacetGrid(hasil_agglo, col='cluster')
    grid.map(plt.hist, i)


```











5. Dekomposisi PCA

```
dist = 1 - cosine_similarity(df)
pca = PCA(n_components = 2)
pca = pca.fit_transform(dist)
```

6. Visualisasi penyebaran agglomerative clustering

```
x, y = pca[:, 0], pca[:, 1]
warna = { 0 : 'red', 1 : 'blue', 2 : 'green' }
label_pca = { 0 : 'cluster 0', 1 : 'cluster 1', 2 : 'cluster 2' }
df = pd.DataFrame({'x' : x, 'y' : y, 'label' : labels})
groups = df.groupby('label')
fig, ax = plt.subplots(figsize=(15, 10))


for name, group in groups:
    ax.plot(group.x, group.y, marker='o', linestyle='', ms=5,
            color = warna[name], label = label_pca[name], mec='none')
```

```

ax.set_aspect('auto')
ax.tick_params(axis='x', which='both', bottom='off',
top='off', labelbottom='off')
ax.tick_params(axis='y', which='both', left='off', top='off',
labelleft='off')

ax.legend()
ax.set_title("Visualisasi Agglomerative Clustering pada Dataset
Kartu Kredit")
plt.show()

```



G. Daftar Pustaka

- Abdulhafedh, A. (2021). Incorporating K-means, Hierarchical Clustering and PCA in Customer Segmentation. *Journal of City and Development*, 3(1), 12–30. <https://doi.org/10.12691/jcd-3-1-3>
- Abdurrahman, G. (2019). Clustering Data Kredit Bank Menggunakan Algoritma Agglomerative Hierarchical Clustering Average Linkage. *JUSTINDO (Jurnal Sistem dan Teknologi Informasi Indonesia)*, 4(1), 13. <https://doi.org/10.32528/justindo.v4i1.2418>

- Hediyati, D., & Suartana, I. M. (2021). Penerapan Principal Component Analysis (PCA) Untuk Reduksi Dimensi Pada Proses Clustering Data Produksi Pertanian Di Kabupaten Bojonegoro. *Journal of Information Engineering and Educational Technology*, 5(2), 49–54. <https://doi.org/10.26740/jieet.v5n2.p49-54>
- Jafarzadegan, M., Safi-Esfahani, F., & Beheshti, Z. (2019). Combining hierarchical clustering approaches using the PCA method. *Expert Systems with Applications*, 137, 1–10. <https://doi.org/10.1016/j.eswa.2019.06.064>
- Nugroho, M. (2003). Bab iii landasan teori 3.1. <http://e-journal.uajy.ac.id/7244/4/3TF03686.pdf>, (Cv), 15–48.
- Shoolihah, A.-M., Furqon, M. T., & Widodo, A. W. (2017). Implementasi Metode Improved K-Means untuk Mengelompokkan Titik Panas Bumi. *Jurnal Pengembangan Teknologi Informasi dan Ilmu Komputer*, 1(11), 1270–1276. Diambil dari <https://j-ptiik.ub.ac.id/index.php/j-ptiik/article/view/453>
- Widyawati, W., Saptomo, W. L. Y., & Utami, Y. R. W. (2020). Penerapan Agglomerative Hierarchical Clustering Untuk Segmentasi Pelanggan. *Jurnal Ilmiah SINUS*, 18(1), 75. <https://doi.org/10.30646/sinus.v18i1.448>
- Yuda Irawan. (2019). Penerapan Data Mining Untuk Evaluasi Data Penjualan Menggunakan Metode Clustering Dan Algoritma Hirarki Divisive Di Perusahaan Media World Pekanbaru. *Jurnal Teknologi Informasi Universitas Lambung Mangkurat (JTIULM)*, 4(1), 13–20. <https://doi.org/10.20527/jtiulm.v4i1.34>